

طبقه‌بندی ضایعات سرطان پوست با استفاده از یادگیری عمیق قابل تفسیر

محمد ضیاالرحمان رحمان

۱، ۲، فواد احمد

۲، سلیمان ا. السحیبیانی

۳، ۴، ۵، سجاد شوکت جمال

۴، محمد ذوالفقار علی

۵ و جواد احمد

چکیده:

سرطان پوست یکی از شایع‌ترین و کشنده‌ترین انواع سرطان در سراسر جهان است. روش‌های سنتی تشخیص سرطان پوست نیاز به معاینه فیزیکی دقیق توسط متخصص پزشکی دارد که در برخی موارد زمان‌بر است. اخیراً سیستم‌های تشخیص پزشکی کمک‌رایانه‌ای به دلیل اثربخشی و کارایی خود محبوبیت یافته‌اند. این سیستم‌ها می‌توانند به متخصصان پوست در تشخیص زودهنگام سرطان پوست که می‌تواند نجات‌بخش باشد، کمک کنند. در این مقاله، مدل‌های از پیش آموزش‌دیده یادگیری عمیق DenseNet201 و MobileNetV2 با افزودن لایه‌های کانولوشن اضافی برای تشخیص مؤثر سرطان پوست اصلاح شده‌اند. به طور خاص، برای هر دو مدل، اصلاح شامل قرار دادن سه لایه کانولوشن در انتهای هر دو مدل است. یک مقایسه دقیق ثابت می‌کند که مدل‌های اصلاح شده برتری خود را نسبت به مدل‌های از پیش آموزش‌دیده اصلی DenseNet201 و MobileNetV2 نشان می‌دهند. روش پیشنهادی می‌تواند هر دو کلاس خوش‌خیم و بدخیم را تشخیص دهد. نتایج نشان می‌دهد که مدل اصلاح‌شده DenseNet201 پیشنهادی با دقت ۹۵.۵۰٪ و عملکردی در سطح پیشرفتی در مقایسه با سایر تکنیک‌های موجود در ادبیات موضوع دست می‌یابد. علاوه بر این، حساسیت و ویژگی مدل اصلاح‌شده DenseNet201 به ترتیب ۹۳.۹۶٪ و ۹۷.۰۳٪ است.

کلیدواژه‌ها:

طبقه‌بندی؛ یادگیری عمیق؛ هوش مصنوعی قابل تفسیر (XAI)؛ سرطان پوست؛ یادگیری انتقالی

Classification of Skin Cancer Lesions Using Explainable Deep Learning .pdf

PDF 8.59MB

کل متن این مقاله رو به فارسی ترجمه کن غیر از reference که به زبان اصلی باشد

ترجمه مقاله: طبقه‌بندی ضایعات سرطان پوست با استفاده از یادگیری عمیق قابل تفسیر

سنسورها

مقاله

طبقه‌بندی ضایعات سرطان پوست با استفاده از یادگیری عمیق قابل تفسیر

محمد ضیاالرحمان رحمان

۱، ۲، فواد احمد

۲، سلیمان ا. السحیبیانی

۳، ۴، ۵، سجاد شوکت جمال

چکیده:

سرطان پوست یکی از شایع‌ترین و کشنده‌ترین انواع سرطان در سراسر جهان است. روش‌های سنتی تشخیص سرطان پوست نیاز به معاینه فیزیکی دقیق توسط متخصص پزشکی دارد که در برخی موارد زمان‌بر است. اخیراً سیستم‌های تشخیص پزشکی کمک‌ایانه‌ای به دلیل اثربخشی و کارایی خود محبوبیت یافته‌اند. این سیستم‌ها می‌توانند به متخصصان پوست در تشخیص زودهنگام سرطان پوست که می‌تواند نجات‌بخش باشد، کمک کنند. در این مقاله، مدل‌های از پیش آموزش‌دیده یادگیری عمیق DenseNet201 و MobileNetV2 با افزودن لایه‌های کانولوشن اضافی برای تشخیص مؤثر سرطان پوست اصلاح شده‌اند. به طور خاص، برای هر دو مدل، اصلاح شامل قرار دادن سه لایه کانولوشن در انتهای هر دو مدل است. یک مقایسه دقیق ثابت می‌کند که مدل‌های اصلاح شده برتری خود را نسبت به مدل‌های از پیش آموزش‌دیده اصلی DenseNet201 و MobileNetV2 نشان می‌دهند. روش پیشنهادی می‌تواند هر دو کلاس خوش‌خیم و بدخیم را تشخیص دهد. نتایج نشان می‌دهد که مدل اصلاح شده DenseNet201 پیشنهادی با دقت ۹۵.۵٪ و عملکردی در سطح پیشرفت‌های معمولی با سایر تکنیک‌های موجود در ادبیات موضوع دست می‌یابد. علاوه بر این، حساسیت و ویژگی مدل اصلاح شده DenseNet201 به ترتیب ۹۳.۹۶٪ و ۹۷.۰۳٪ است.

کلیدواژه‌ها:

طبقه‌بندی؛ یادگیری عمیق؛ هوش مصنوعی قابل تفسیر(XAI)؛ سرطان پوست؛ یادگیری انتقالی

۱. مقدمه

بر اساس آمار سازمان جهانی بهداشت(WHO)، سرطان پوست یک سوم از تمام موارد گزارش شده سرطان را تشکیل می‌دهد و نرخ شیوع آن در سراسر جهان در حال افزایش است [۱]. در طول دهه گذشته، افزایش چشمگیری در سرطان پوست در ایالات متحده، استرالیا و کانادا گزارش شده است. تقریباً هر سال ۱۵۰۰۰ نفر پس از ابتلا به سرطان پوست جان خود را از دست می‌دهند [۲]. یک مطالعه آمریکایی نشان می‌دهد که در سال ۲۰۲۱، ۷۱۸۰ نفر ترها به دلیل یک نوع سرطان (ملانوما) جان باختند و انتظار می‌رود در سال ۲۰۲۲، نزدیک به ۷۶۵۰ نفر به دلیل سرطان ملانوما فوت کنند [۳]. کاهش لایه اوزون میزان تابش خط‌رنگ فرابنفش (UV) که به سطح زمین می‌رسد را افزایش می‌دهد. تابش‌های فرابنفش می‌توانند به سلول‌های پوست آسیب برسانند که ممکن است منجر به رشد سرطانی سلول‌ها شود. تابش خط‌رنگ فرابنفش می‌تواند طیف وسیعی از عوایق نامطلوب را ایجاد کند و یکی از آن‌ها نرخ فرزینده بروز سرطان پوست است [۴]. برخی عوامل دیگر از جمله سیگار کشیدن، مصرف الکل، عفونت‌های مختلف، ویروس‌ها و محیط زندگی نیز رشد سلول‌های سرطانی را تحریک می‌کنند. دو نوع اصلی تومور پوستی وجود دارد؛ برخی تومور‌ها سرطانی هستند در حالی که برخی دیگر غیرسرطانی هستند. تومور بدخیم سرطانی است و انواع بیشتری دارد [۵]. شایع‌ترین ضایعات بدخیم پوست شامل سرطان سلول سنگفرشی(SCC)، سرطان سلول پایه‌ای(BCC)، ملانوم بدخیم و درماتوفیروسارکوم هستند. انواع دیگر شامل سرطان پوستی چسبنده بدخیم، فیبروس هیستیوسیتوم، سارکوم کاپوسی و سارکوم پلئومورفیک

[۵-۶] می‌باشد. ملانوم بدخیم سرطان پوستی نادری است اما در بین آن‌ها کشنده‌ترین سرطان محسوب می‌شود. تومورهای بدخیم از طریق سیستم لنفاوی یا رگ‌های خونی به سایر اندام‌های بدن گسترش می‌یابند؛ این گسترش متاستاز نامیده می‌شود.^۸

رشد غیرطبیعی سلول‌های ملانوسیتیک پوست باعث ملانوم بدخیم می‌شود. قرار گرفتن پوست در معرض نور خورشید ملانین تولید می‌کند که به طور طبیعی از پوست در برابر اثرات نامطلوب نور خورشید محافظت می‌کند، با این حال، اگر ملانین تجمع یابد، تومور شروع به رشد می‌کند [۹]. در بسیاری از موارد، برداشت کامل (جراحی) ناحیه آلوهه توسط جراحان منجر به بهبودی می‌شود. علاوه بر این، در چندین مورد، نیاز به بازسازی ناحیه آلوهه وجود دارد که توسط جراحان پلاستیک انجام می‌شود [۷]. از طرف دیگر، تومور خوش‌خیم غیرسرطانی است و به سایر اندام‌ها گسترش نمی‌یابد اما قابلیت بزرگ کردن تکه‌های ضایعه و تومورها را دارد. انواع مختلف تومورهای خوش‌خیم شامل کراتوز سبورئیک، آنژیوم گیلاسی، درماتوفیبروما، تگ‌های پوستی (آکروکوردون)، گرانولوم پیوژنیک و کیست‌ها هستند^{۱۰}، [۵].

برای تشخیص سرطان پوست، پزشک یک سری مراحل را انجام می‌دهد. در مرحله اول، ضایعات با چشم غیرمسلح بررسی می‌شوند. برای بررسی بیشتر، از درموسکوپی برای بررسی بیشتر الگوی ضایعات پوستی استفاده می‌شود. در این فرآیند، یک ژل روی ضایعات پوستی قابل مشاهده اعمال می‌شود و تحت یک ابزار بزرگنمایی برای مشاهده بهتر بررسی می‌شود [۱۱]. برای تجزیه و تحلیل دقیق‌تر، بخشی از ناحیه مشکوک پوست برداشته شده و برای بررسی میکروسکوپی به آزمایشگاه فرستاده می‌شود؛ این روش بیوپسی نامیده می‌شود. برخی از متخصصان ضایعه پوستی را بر اساس تکنیک ABCDE تشخیص می‌دهند که در آن تعدادی از عوامل از جمله رنگ، حاشیه، عدم تقارن، قطر ضایعه و تکامل ضایعه در طول زمان تحلیل می‌شود [۱۲]. با این حال، بررسی صرفاً به مهارت متخصصان پوست همراه با امکانات بالینی بستگی دارد. تشخیص و شناسایی به موقع سرطان، به ویژه سرطان پوست، می‌تواند از گسترش بیشتر جلوگیری کرده و به طور مؤثر درمان شود. علاوه بر این، تشخیص زودهنگام سرطان پوست به کاهش نرخ مرگ و میر و روش‌های پزشکی پرهزینه کمک می‌کند [۱۳]. علاوه بر این، روش دستی برای بررسی سرطان پوست زمان بر است و ممکن است در طول فرآیند تشخیص احتمال خطای انسانی وجود داشته باشد. از دهه گذشته، استفاده از سیستم‌های کمکرایانه‌ای در حوزه پزشکی دیده شده است. چنین سیستم‌هایی می‌توانند برای تشخیص سرطان پوست استفاده شوند. به طور سنتی، ویژگی‌های مختلف مرتبط با پوست مانند رنگ، بافت، شکل و غیره استفاده شده‌اند [۱۴]. استخراج چندین ویژگی نه تنها زمان بر است بلکه فرآیندی پیچیده است. با این حال، توسعه‌های اخیر در حوزه هوش مصنوعی راه را برای استخراج ویژگی با استفاده از معماری‌های یادگیری عمیق هموار کرده است. معماری‌های یادگیری عمیق می‌توانند با استفاده از شبکه‌های عصبی کانولوشنی (CNN) چندین ویژگی را استخراج کنند [۱۵]. CNN می‌تواند ویژگی‌ها را در مقایسه با روش‌های سنتی استخراج ویژگی به طور کارآمد استخراج کند. اخیراً از سیستم‌های کمکرایانه‌ای مبتنی بر یادگیری عمیق برای تشخیص بیماری‌های مختلف استفاده شده و نتایج قابل توجهی نشان داده‌اند. پتانسیل عظیمی برای استفاده از سیستم‌های کمکرایانه‌ای برای کمک به پرسنل پزشکی در تشخیص بیماری در مراحل اولیه آن وجود دارد.

۲. کارهای مرتبط

اخیراً طرح‌های متعددی برای طبقه‌بندی ضایعات پوستی با استفاده از معماری‌های یادگیری عمیق توسعه یافته است. برخی از تکنیک‌های اخیر برای طبقه‌بندی ضایعات پوستی در این بخش مورد بحث قرار گرفته‌اند.

دورج و همکاران [۱۶] از یک مدل از پیش آموزش دیده AlexNet برای فرآیند استخراج ویژگی استفاده کردند، در حالی که SVM برای طبقه‌بندی استفاده شد. تکنیک طبقه‌بندی ضایعات پوستی نتایج چشمگیری ارائه داد. فیلهو و همکاران [۱۷]

تکنیکی برای طبقه‌بندی صنایعات پوستی با استفاده از ماتریس هم‌خداد ساختاری (SCM) ارائه کردند. برای استخراج ویژگی‌های بافت از تصاویر در موسکوپی استفاده می‌شود. آزمایش بر روی مجموعه داده‌های ISIC 2016 و ISIC 2017 انجام شد. برای طبقه‌بندی، الگوریتم‌های یادگیری مختلفی استفاده شد و در بین آن‌ها SVM بهترین نتایج را ارائه داد. این تکنیک ویژگی ۹۰٪ را به دست آورد. لی و همکاران [۱۸] یک شبکه نایمه‌سازی صنایعه جدید را برای طبقه‌بندی صنایعات پوستی پیشنهاد کردند LIN. از یک الگوریتم یادگیری عمیق تشکیل شده است که قادر به استخراج ویژگی‌های اضافی در مقایسه با یک الگوریتم یادگیری عمیق ساده است. طرح پیشنهادی نتایج طبقه‌بندی خوبی با دقت ۹۱.۲٪ به دست آورد. این طرح همچنین می‌تواند صنایعات را بخش‌بندی کند، با این حال، نتایج برای بخش‌بندی صنایعات نیاز به بیبود قابل توجهی داشت. صبا و همکاران [۱۹] یک رویکرد مبتنی بر یادگیری عمیق برای تشخیص سرطان پوست پیشنهاد کردند. برای بهبود کیفیت بصری مجموعه داده‌های استفاده شده، از تکنیک کشش کنتر استفاده شد. علاوه بر این، برای تخمين مرز صنایعات، یک CNN به دنبال عملیات XOR استفاده شد. ویژگی‌ها با استفاده از Inceptionv3 و با کمک یادگیری انتقالی استخراج می‌شوند. برای آزمایش، از مجموعه داده‌های PH2 و ISIC 2017 استفاده شد.

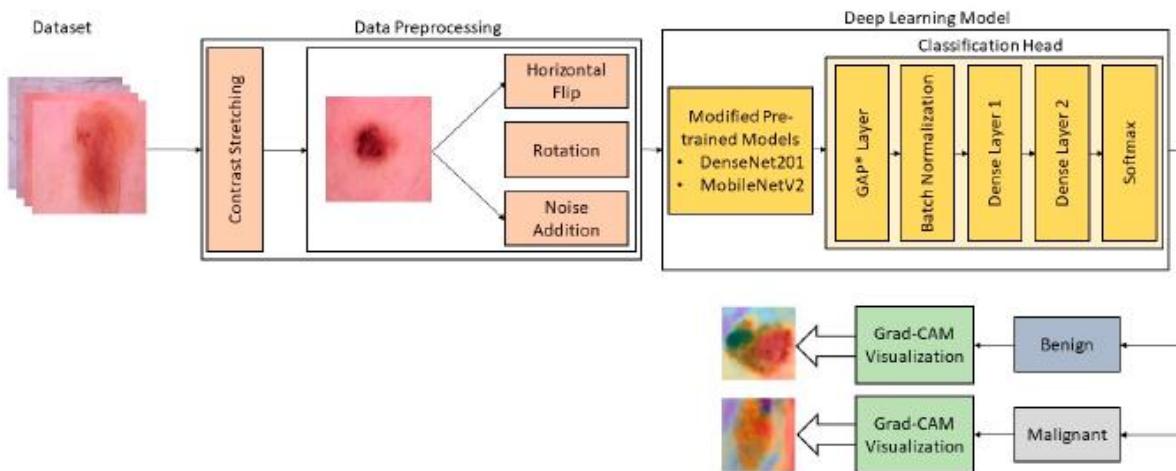
استوا و همکاران [۲۰] تکنیکی برای طبقه‌بندی سرطان پوست با استفاده از مدل InceptionV3 پیشنهاد کردند. از تصاویر بالینی برای آموزش و ارزیابی استفاده شد. نتایج تکنیک پیشنهادی توسط یک هیئت ۲۱ نفره معتبر برای دو کشنده‌ترین سرطان‌های پوستی مورد بازخواست مقابل قرار گرفت. لی و همکاران [۲۱] یک تکنیک یادگیری عمیق مبتنی بر مدل ResNet50 ارائه کردند که از رویکرد یادگیری انتقالی برای آموزش مدل استفاده می‌کند. هایپرپارامترها برای بهبود عملکرد مدل تنظیم دقیق شدند. علاوه بر این، برای جلوگیری از بیشبرازش، به جای لایه پولینگ میانگین، از لایه‌های پولینگ میانگین سراسری استفاده شد. در این کار از مجموعه داده HAM10000 استفاده شد. اقبال و همکاران [۲۲] تکنیکی برای طبقه‌بندی صنایعات پوستی بر اساس شبکه‌های عصبی کانولوشنی عمیق ارائه کردند. مدل استفاده شده در این کار شامل چندین بلوک به صورت تشکیل از بالا به پایین است که اطلاعات ویژگی را در مقیاس‌های مختلف ارائه می‌دهد. این مدل شامل ۶۸ لایه کانولوشنی است و در این کار از مجموعه داده 2019-2017 ISIC استفاده شد. اسربینیوسا و همکاران [۲۳] تکنیکی را پیشنهاد کردند که از شبکه‌های MobileNetV2 و LSTM استفاده می‌کند. تکنیک پیشنهادی برای طبقه‌بندی صنایعات استفاده می‌شود که بر روی مجموعه داده HAM10000 انجام می‌شود. MobileNetV2 یک مدل سبکوزن است که به توان محاسباتی کمی نیاز دارد و با دستگاه‌های انتهایی قابل انطباق است. از شبکه LSTM برای حفظ جزئیات زمانی ویژگی‌های استخراج شده از MobileNetV2 استفاده می‌شود. ترکیب LSTM با MobileNetV2 دقت را تا ۸۵٪ بهبود بخشد.

شاهین و همکاران [۲۴] یک تکنیک یادگیری عمیق مبتنی بر شبکه‌های عصبی کانولوشنی عمیق برای طبقه‌بندی خودکار سرطان پوست پیشنهاد کردند. تکنیک پیشنهادی می‌تواند طبقه‌بندی بالیری را برای سرطان‌های پوستی برای هر دو مورد خوش‌خیم و بدخیم انجام دهد. مراحل پیش‌پردازش مختلف شامل حذف نویز، نرمال‌سازی و افزایش داده است. در این کار چندین مدل یادگیری عمیق برای دستیابی به دقت طبقه‌بندی بهتر و مؤثرتر مقایسه شدند. تکنیک پیشنهادی دقت آزمایشی ۹۱.۹۳٪ را در مجموعه داده معروف HAM10000 به دست آورد. فرهت و همکاران [۲۵] روشی برای طبقه‌بندی سرطان پوست با استفاده از یک الگوریتم یادگیری عمیق ارائه کردند. دو مجموعه داده مختلف استفاده شده است که عبارتند از HAM10000 و ISIC 2018. ISIC تکنیک پیشنهادی شامل تعدادی مرحله است که مراحل اصلی آن استخراج ویژگی با استفاده از مدل یادگیری عمیق و انتخاب ویژگی با استفاده از یک الگوریتم فرابتکاری است. طبقه‌بندی نهایی با استفاده از یادگیری ماشین افراطی با دقت به ترتیب ۹۳.۴۰٪ و ۹۴.۳۶٪ برای HAM10000 و ISIC2018 انجام شد. چاتوروودی و همکاران [۲۶] یک تکنیک طبقه‌بندی چندکلاسه پوست مبتنی بر مدل‌های یادگیری عمیق پیشنهاد کردند. سیستم خودکار مبتنی بر یادگیری عمیق تمايل به بهبود دقت طبقه‌بندی دارد. مدل‌های یادگیری عمیق برای بهبود دقت مدل‌ها تنظیم دقیق

می‌شوند؛ علاوه بر این، از مدل‌های ترکیبی نیز برای مقایسه استفاده شده است. این تکنیک دقت ۹۳.۲۰٪ را در مجموعه داده HAM10000 به دست آورد.

۳. مواد و روش‌ها

یک چارچوب جدید برای طبقه‌بندی ضایعات پوستی در این بخش ارائه شده است. چارچوب پیشنهادی می‌تواند ضایعات سرطانی و غیرسرطانی را با استفاده از مدل‌های یادگیری عمیق متایز کند. چارچوب پیشنهادی به یک سری مراحل برای طبقه‌بندی کارآمد ضایعات نیاز دارد. این کار با افزایش مجموعه داده موجود آغاز می‌شود و به دنبال آن مراحل برای آموزش مجدد مدل یادگیری عمیق که شامل یادگیری انتقالی، تنظیم دقیق مدل همراه با تنظیم هایپرپارامتر است، دنبال می‌شود. مدل تنظیم شده قادر به استخراج ویژگی‌های موردنظر برای طبقه‌بندی ضایعات سرطان پوست است. دو تکنیک یادگیری عمیق مختلف در این کار استفاده شده است. مجموعه داده افزایش یافته برای مدل یادگیری عمیق تنظیم شده مطابق با الزامات این کار استفاده می‌شود. گردش کار کلی چارچوب پیشنهادی در شکل ۱ ارائه شده است. هر مرحله از گردش کار در بخش‌های زیر مورد بحث قرار گرفته است.



شکل ۱. گردش کار تکنیک پیشنهادی برای طبقه‌بندی سرطان پوست.

مجموعه داده و پیش‌پردازش داده

مجموعه داده نیاز اولیه برای استفاده از مدل‌های یادگیری عمیق برای مسائل مختلف است. مجموعه داده‌ها به راحتی در دسترس نیستند و علاوه بر این، مجموعه داده‌های تمیز و آماده شده نادر هستند. مدل‌های یادگیری عمیق الگوها و ویژگی‌های مجموعه داده را می‌آموزند و بر اساس الگوها و ویژگی‌های آموخته شده می‌توانند پیش‌بینی انجام دهند. یک مجموعه داده تمیز و آماده شده نیاز کلیدی برای دستیابی به عملکرد پیشرفته با استفاده از مدل‌های یادگیری عمیق است. در این کار، مجموعه داده از کلک (۲۰۱۷) به دست آمده است. کلک یک پلتفرم شناخته شده برای جامعه علمی است؛ این مجموعه داده بخشی از آرشیو ISIC است [۲۸]. مجموعه داده شامل دو دسته است: بدخیم و خوشخیم. در مجموع ۳۲۹۷ تصویر در این مجموعه داده موجود است. دسته "خوشخیم" شامل ۱۸۰۰ تصویر است، در حالی که "بدخیم" شامل ۱۴۹۷ تصویر است.

پیش‌پردازش داده یک مرحله حیاتی در افزایش کیفیت هر مجموعه داده است [۲۹]. این شامل رویکردهای متعددی است؛ در این کار، کیفیت بصری مجموعه داده با استفاده از کشش کنتراست افزایش یافته است. این به طور قابل توجهی کیفیت

تصاویری را بهبود میبخشد که نقاط ضایعه در طول فرآیند کسب تصویر محو شده‌اند. چند نمونه تصویر با کنتر است افزایش یافته در شکل ۲ نشان داده شده است.

ثانیاً، مدل‌های یادگیری عمیق به مقدار زیادی داده برای آموزش نیاز دارند [۳۰]. [برای افزایش نمونه‌های آموزشی مجموعه داده، از افزایش داده استفاده می‌شود. تکنیک‌های مختلف افزایش داده در ادبیات برای سناریوهای مختلف وجود دارد. سه تکنیک افزایش داده مختلف در این کار استفاده شده است: چرخش، معکوس‌سازی و افزودن نویز. چرخش و معکوس‌سازی عملیات افزایش داده ناوردا به مقیاس هستند. تصاویر در ۱۵ و ۴۵ درجه در هر دو جهت عقربه‌های ساعت و خلاف جهت عقربه‌های ساعت چرخانده شده و به دنبال آن معکوس‌سازی افقی انجام می‌شود [۳۱]. آخرین تکنیک افزایش داده استفاده شده در این کار افزودن نویز است که معمولاً به عنوان افزایش نویز شناخته می‌شود. این تمایل به تزریق نویز تصادفی به مجموعه داده برای افزایش تعداد نمونه‌های موجود در مجموعه داده دارد. این تکنیک نه تنها مجموعه داده را بزرگ می‌کند بلکه خطای تعمیم را در طول فرآیند آموزش مدل یادگیری عمیق کاهش می‌دهد و فرآیند آموزش را قوی می‌سازد [۳۲]. نویز گاوی با واریانس ۱.۰ به مجموعه داده اضافه شده است. توضیح دقیقی از مجموعه داده در جدول ۱ ارائه شده است. چند نمونه از مجموعه داده افزایش یافته در شکل ۳ نشان داده شده است.

جدول ۱. توضیح دقیق مجموعه داده

تصاویر آزمون تصاویر اعتبارسنجی تصاویر آموزشی تصاویر افزایش یافته تصاویر اصلی دسته‌ها

خوش‌خیم	۱۸۰۰	۳۷۲۷	۲۶۰۹	۷۴۵	۳۷۳
بدخیم	۱۴۹۷	۳۶۰۰	۲۵۲۰	۷۲۰	۳۶۰
مجموع	۳۲۹۷	۷۳۲۷	۵۱۲۹	۱۴۶۵	۷۳۳

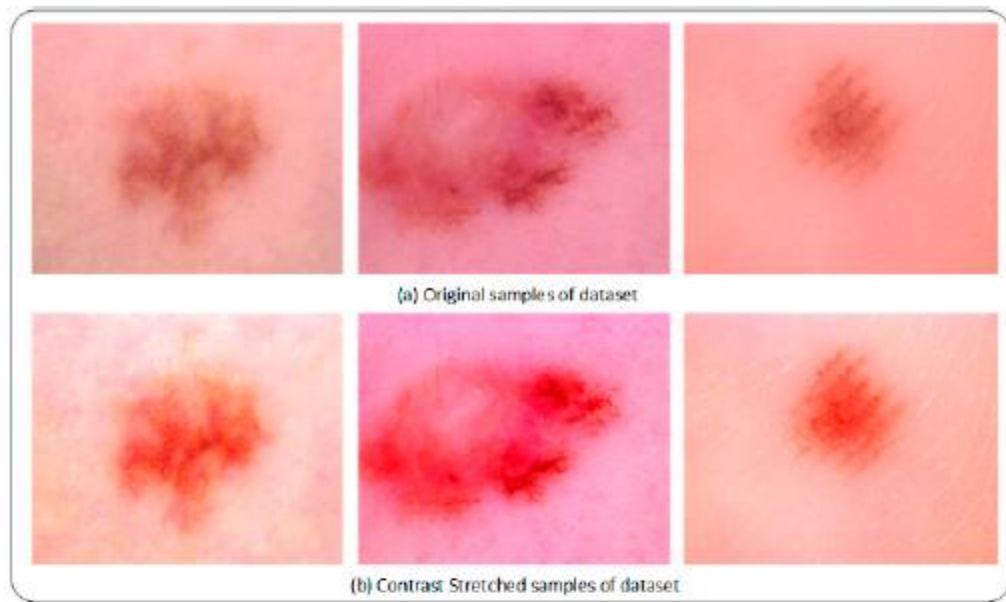


Figure 2. Illustration of contrast-enhanced image.

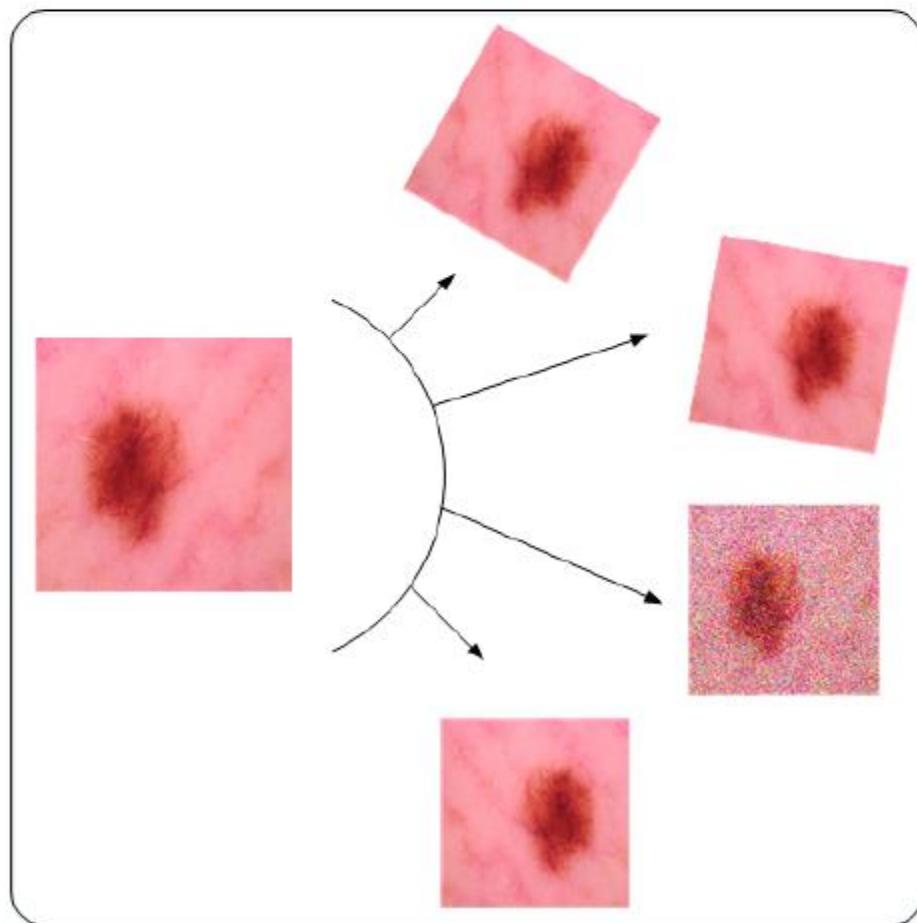


Figure 3. Visual illustration of the augmentation techniques.

(الف) نمونه‌های اصلی مجموعه داده

(ب) نمونه‌های کشش کنتراست یافته مجموعه داده

شکل ۲. نمایش تصویر با کنتراست افزایش یافته.

شکل ۳. نمایش بصری تکنیک‌های افزایش داده.

مدل‌های یادگیری عمیق

یادگیری عمیق زیرشاخه‌ای از هوش مصنوعی (AI) است که رفتار مغز انسان را تقلید می‌کند. در طول دهه گذشته، زمانی که در زمینه‌های مختلف برای اهداف مختلف استفاده شد و نتایج برتری نسبت به

الگوریتم‌های موجود دیگر ارائه داد، در کانون توجه قرار گرفت. به آن "یادگیری عمیق" گفته می‌شود زیرا از تعداد زیادی لایه پنهان تشکیل شده است که معمولاً لایه‌های کانولوشنی هستند [۳۳]. این لایه‌های کانولوشن پنهان برای استخراج ویژگی استفاده می‌شوند. مدل‌های یادگیری عمیق گامی به سوی انوماسیون سیستم‌های کمکرایانه‌ای هستند. این مدل‌ها برای اهداف مختلف از جمله طبقه‌بندی، بخش‌بندی، تشخیص اشیا و غیره در زمینه‌های مختلفی مانند کشاورزی، پزشکی، خودروهای بدون راننده و بسیاری دیگر استفاده شده‌اند.

در این کار، دو مدل یادگیری عمیق برای طبقه‌بندی بیماری‌های پوستی استفاده شده است. مدل‌های استفاده شده [۳۴] DenseNet201 و [۳۵] MobileNetV2 هستند. این مدل‌ها با استفاده از یادگیری انتقالی (TL) آموزش دیده‌اند. رویکرد TL نه تنها به مدل در یادگیری ویژگی کمک می‌کند بلکه عملکرد را در حالی که منابع محاسباتی را محدود می‌کند، بهبود می‌بخشد [۳۶]. هر دو مدل اصلاحات جزئی ای را به منظور دستیابی به نتایج مطلوب پشت سر گذاشته‌اند. مدل‌های استفاده شده در زیر، همراه با اصلاحات مورد بحث قرار گرفته‌اند.

۳.۲.۱. MobileNetV2 اصلاح شده

یکی از مدل‌های استفاده شده در این کار MobileNetV2 است که یک مدل شناخته شده برای استخراج ویژگی است. به عنوان یک مدل سبکوزن، به طور گسترده در حوزه تحقیقاتی استفاده می‌شود. مدل از پیش آموزش دیده MobileNetV2 استفاده شده در این کار قبلاً بر روی یک مجموعه داده تصویر بزرگ، [۳۷] ImageNet آموزش دیده است. در این کار، از یادگیری انتقالی برای آموزش مدل از پیش آموزش دیده MobileNetV2 استفاده می‌شود. مدل اصلی MobileNetV2 تصویر با اندازه $224 \times 224 \times 3$ را می‌گیرد. تصویر از طریق یک لایه کانولوشن با 32 فیلتر عبور داده می‌شود. بلوک باقیمانده معکوس (IRB) بلوک غالب MobileNetV2 است که در مقایسه با بلوک‌های کانولوشن معمولی نیاز حافظه را کاهش می‌دهد IRB. شامل کانولوشن نقطه‌ای و عمقی است. کانولوشن عمقی برای حذف ویژگی‌های زائد استفاده می‌شود؛ حذف ویژگی‌های زائد به مدل کمک می‌کند تا عملکرد بهتری داشته باشد در حالی که هزینه محاسباتی پایین را حفظ می‌کند ReLU6. به عنوان تابع فعال‌سازی در سراسر شبکه استفاده شده است [۳۴]. به IRB در MobileNetV2 معمولاً به عنوان گلوگاه اشاره می‌شود؛ ۱۷ گلوگاه از این نوع در MobileNetV2 وجود دارد. شکل ۴ معماری MobileNetV2 اصلاح شده پیشنهادی را نشان می‌دهد.

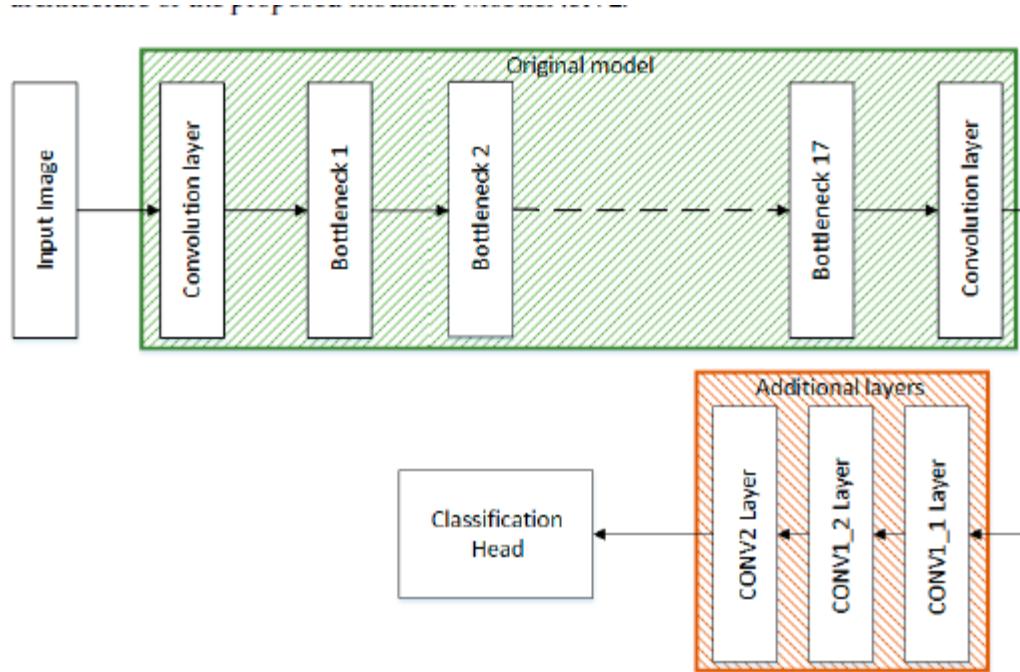


Figure 4. Architecture of the proposed modified MobileNetV2.

شکل ۴. معماری MobileNetV2 اصلاح شده پیشنهادی.

در این کار، سه لایه کانولوشن دو بعدی در انتهای شبکه قرار داده شده‌اند که عملکرد مدل را به طور قابل توجهی بهبود می‌بخشد. لایه CONV1 حاوی 128×3 فیلتر با اندازه کرنل 1×3 است، لایه CONV2 نیز حاوی 128×3 فیلتر با اندازه کرنل 1×3 است. لایه کانولوشن نهایی CONV2 حاوی 64×3 فیلتر با اندازه کرنل 3×3 است. سر طبقه‌بندی برای طبقه‌بندی نهایی استفاده می‌شود و از یک لایه GAP، یک لایه نرمال‌سازی دسته‌ای و دو لایه چگال تشکیل شده است. لایه چگال نهایی مطابق با نیازهای مطلوب اصلاح شده است.

۳.۲.۲. اصلاح شده DenseNet201

مدل دیگر استفاده شده برای استخراج ویژگی، مدل از پیش آموزش دیده DenseNet201 است که عدد ۲۰۱ به ۲۰۱ لایه مدل اصلی اشاره دارد. مدل DenseNet201 نیز بر روی مجموعه داده ImageNet آموزش دیده است. از یادگیری انتقالی برای آموزش مدل برای کار مورد نظر طبقه‌بندی بیماری‌های پوستی استفاده می‌شود. مدل DenseNet201 از ۴ بلوک چگال و ۳ لایه انتقالی تشکیل شده است که به عنوان اتصالات بین دو بلوک چگال عمل می‌کنند. در داخل بلوک چگال، هر لایه کانولوشن به لایه‌های کانولوشن دیگر متصل است. پس از هر بلوک چگال، اندازه نقشه ویژگی افزایش می‌یابد. لایه‌های انتقالی به عنوان لایه‌های نمونه‌برداری پایین‌رونده عمل می‌کنند. در DenseNet201، نمونه‌برداری پایین‌رونده با استفاده از پولینگ میانگین انجام می‌شود [۳۵]. معماری DenseNet201 اصلاح شده پیشنهادی در شکل ۵ نشان داده شده است.

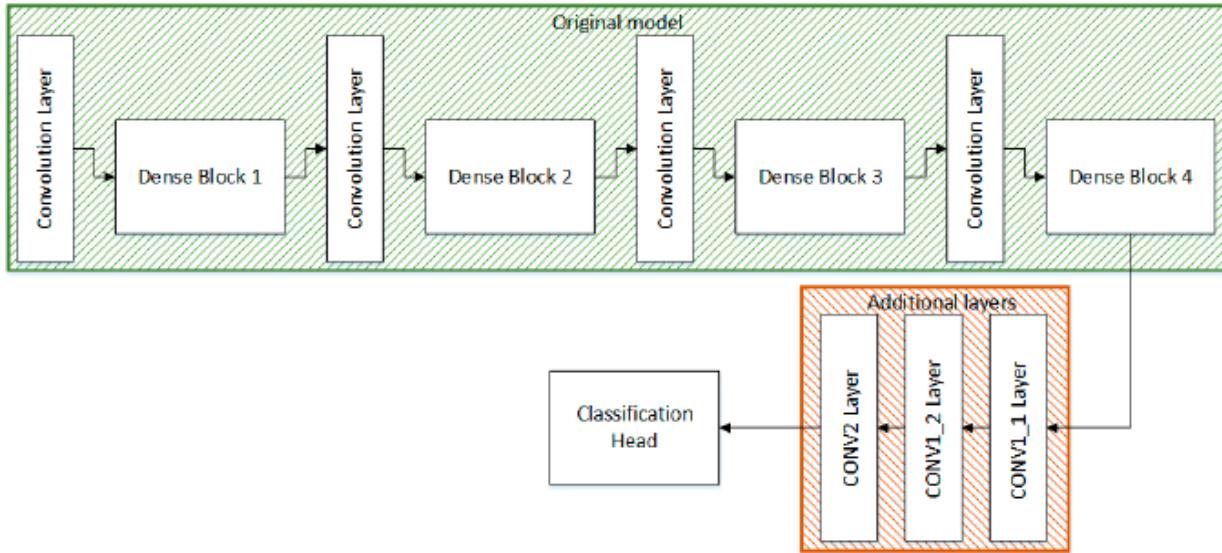


Figure 5. Architecture of the proposed Modified DenseNet201.

شکل ۵. معماری DenseNet201 اصلاح شده پیشنهادی.

برخی لایه های کانولوشنی نیز در انتهای بلوک چگال چهارم قرار داده شده اند. لایه کانولوشنی، یعنی لایه CONV1_1 از ۱۲۸ فیلتر با اندازه کرنل 1×3 تشکیل شده است و لایه کانولوشن CONV1_2 حاوی ۱۲۸ فیلتر با اندازه کرنل 3×3 است. هدف از تجزیه کرنل 3×3 به کرنل های 1×3 و 3×1 کاهش توان محاسباتی است. سومین لایه کانولوشن، CONV_2 با ۶۴ فیلتر با اندازه کرنل 3×3 ساخته شده است. ویژگی های استخراج شده به سر طبقه بندی تغذیه می شوند که شامل GAP، یک لایه نرمال سازی دسته ای، ۲ لایه چگال و طبقه بندی کننده Softmax است. جدول ۲ معماری DenseNet201 اصلاح شده پیشنهادی را شرح می دهد.

جسم Grad-CAM

در این کار، از تجسم نقشه برداری فعال سازی کلاس-وزن دار گرادیان (Grad-CAM) برای دریافت بینش در مورد یادگیری ویژگی با استفاده از مدل یادگیری عمیق استفاده می شود. به طور کلی، مدل های یادگیری عمیق به عنوان جعبه سیاه در نظر گرفته می شوند، زیرا ورودی را گرفته و خروجی پیش بینی خود را می دهند. اخیراً از تجسم Grad-CAM برای درک آنچه در داخل مدل یادگیری عمیق اتفاق می افتد استفاده شده است. یک نمایش از تجسم Grad-CAM در شکل ۶ نشان داده شده است. این یک تکنیک مکانیابی ضعیف نظارت شده است.

جدول ۲. معماری DenseNet201 اصلاح شده پیشنهادی.

DenseNet20 لایه ها	۱
۲ کام کانولوشن $7 \times 7 \text{ conv}$	

DenseNet20
لایه‌ها ۱

پولینگ max pool
۲، ۲×۲ گام ۲

بلوک چگال) ۱ $\times 1 \times 1 conv$
 $\{3 \times 3 conv\}^6$

لایه انتقالی) ۱ $1 \times 1 conv$

max pool
۲، ۳×۳ گام ۳

بلوک چگال) ۲ $\times 1 \times 1 conv$
 $\{3 \times 3 conv\}^{12}$

لایه انتقالی) ۲ $1 \times 1 conv$

average
۲، ۲×۲ pool گام ۴

بلوک چگال) ۳ $\times 1 \times 1 conv$
 $\{3 \times 3 conv\}^{48}$

لایه انتقالی) ۳ $1 \times 1 conv$

average
۲، ۲×۲ pool گام ۵

بلوک چگال) ۴ $\times 1 \times 1 conv$
 $\{3 \times 3 conv\}^{32}$

CONV1_1 $3 \times 1 conv$
۱۲۸ فیلتر

DenseNet20
لایه‌ها ۱

CONV1_2 ، 1×3 conv فیلتر ۱۲۸

CONV2 ، 3×3 conv فیلتر ۶۴

پولینگ میانگین لایه طبقه‌بندی سراسری

سر طبقه‌بندی

Table 2. Architecture of the proposed Modified DenseNet201.

Layers	DenseNet201
Convolution	$7 \times 7 \text{ conv}$, stride 2
Pooling	$2 \times 2 \text{ max pool}$, stride 2
Dense block (1)	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$
Transition layer (1)	$1 \times 1 \text{ conv}$ $3 \times 3 \text{ max pool}$, stride 2
Dense block (2)	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$
Transition layer (2)	$1 \times 1 \text{ conv}$ $2 \times 2 \text{ average pool}$, stride 2
Dense block (3)	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 48$
Transition layer (3)	$1 \times 1 \text{ conv}$ $2 \times 2 \text{ average pool}$, stride 2
Dense block (4)	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$
CONV1_1	$3 \times 1 \text{ conv}$, filters 128
CONV1_2	$1 \times 3 \text{ conv}$, filters 128
CONV2	$3 \times 3 \text{ conv}$, filters 64
Classification Layer	Global Average Pooling Classification Head

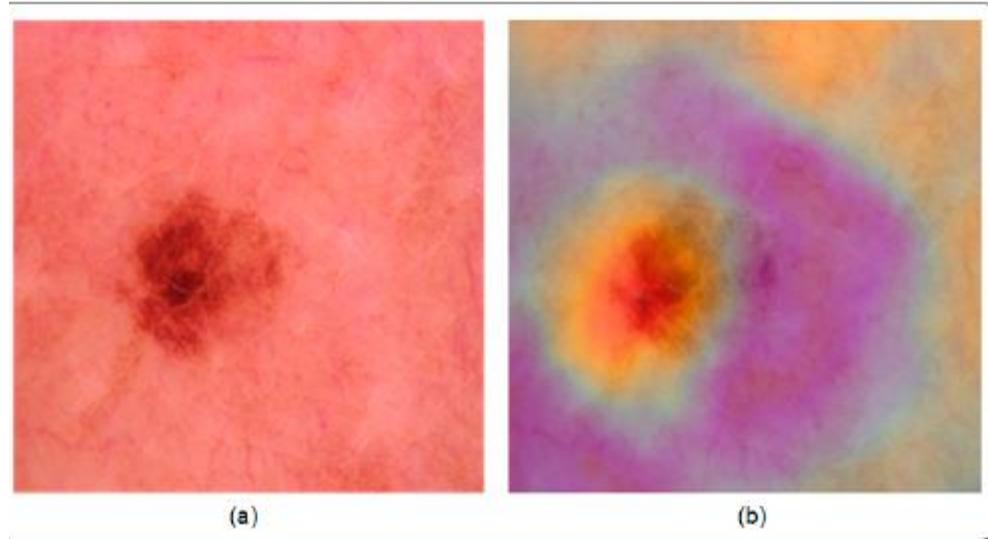


Figure 6. A visual illustration of localization using Grad-CAM. (a) shows the input image and (b) depicts the lesion being weakly localized in the image using Grad-CAM. The result presented in (b) demonstrates the fact that Grad-CAM is capable of localizing lesion present in the image.

(الف) (ب)

شکل ۶. نمایش بصری مکانیابی با استفاده از Grad-CAM (الف) تصویر ورودی را نشان می‌دهد و (ب) ضایعه را که به طور ضعیف در تصویر با استفاده از Grad-CAM مکانیابی شده است، به تصویر می‌کشد. نتیجه ارائه شده در (ب) این واقعیت را نشان می‌دهد که Grad-CAM قادر به مکانیابی ضایعه موجود در تصویر است.

۴. نتایج

نتایج تکنیک پیشنهادی در این بخش ارائه شده است. بخش ۴.۱ اطلاعات مختصری در مورد تنظیمات آزمایشی ارائه می‌دهد. نتایج با استفاده از MobileNetV2 و

DenseNet201 به ترتیب در بخش‌های ۴.۲ و ۴.۳ ارائه شده است. نتایج در بخش ۴.۴ تحلیل و مقایسه شده‌اند.

۴.۱. تنظیمات آزمایشی

مجموعه داده استفاده شده در این کار از گگل گرفته شده است و شامل دو کلاس است. مجموعه داده به گونه‌ای تقسیم شده است که ۷۰٪ برای آموزش، ۲۰٪ برای اعتبارسنجی و ۱۰٪ باقیمانده برای آزمون استفاده می‌شود. از Google Colab برای اجرای مدل‌های DenseNet201، MobileNetV2 و مدل‌های اصلاح شده پیشنهادی آن‌ها استفاده شده است.

۴.۲. نتایج بر اساس MobileNetV2

نتایج با استفاده از MobileNetV2 و MobileNetV2 اصلاح شده پیشنهادی در جدول ۳ نشان داده شده است. MobileNetV2 دقیق‌تر ۹۰.۵۴٪ را هنگام آموزش بر روی مجموعه داده به دست می‌آورد. حساسیت و ویژگی به دست آمده به ترتیب ۹۰.۶۲٪ و ۹۱.۳۲٪ و ۸۹.۹۳٪ و ۹۱.۱۸٪ بود، در حالی که دقیق و حساسیت و نمرات F1 به ترتیب ۹۱.۳٪ و ۹۱.۱۸٪ و ۹۱.۰۹٪ بودند. نتایج MobileNetV2 اصلاح شده پیشنهادی نیز در جدول ۳ ارائه شده است که نشان می‌دهد اصلاح شده دقیق ۹۱.۸۶٪ را به دست می‌آورد. سایر پارامترها از جمله حساسیت، ویژگی، دقیق و نمرات F1 به ترتیب ۹۱.۰۹٪، ۹۱.۹۵٪، ۹۲.۶۶٪ و ۹۲.۸۲٪ ثبت شده‌اند. علاوه بر این، نتایج ارائه شده در جدول ۳ همچنین از طریق ماتریس اشتباہ که در شکل ۷ ارائه شده است، تأیید می‌شود.

شکل ۷. الف ماتریس اشتباہ MobileNetV2 را نشان می‌دهد در حالی که شکل ۷ ب نتایج اصلاح شده پیشنهادی را با استفاده از ماتریس اشتباہ نشان می‌دهد. شکل ۷ الف نشان می‌دهد که مدل MobileNetV2 قادر به تشخیص کلاس خوش‌خیم با دقیق ۸۹٪ است، در حالی که ۱۱٪ از کلاس خوش‌خیم به عنوان بدхیم طبقه‌بندی شد. کلاس بدخیم با دقیق ۹۱٪ به درستی تشخیص داده شد. به طور مشابه، شکل ۷ ب نشان می‌دهد که مدل MobileNetV2 اصلاح شده پیشنهادی کلاس خوش‌خیم را با دقیق ۹۱٪ تشخیص می‌دهد و ۹٪ از کلاس خوش‌خیم به اشتباہ به عنوان بدخیم طبقه‌بندی شد. علاوه بر این، کلاس بدخیم دقیق تشخیص

جدول ۳. نتایج طبقه‌بندی با استفاده از MobileNetV2.

نمره F1	دقیق	ویژگی	حساسیت	دقیق	مدل یادگیری عمیق
---------	------	-------	--------	------	------------------

MobileNetV2	۹۰.۵۴٪	۸۹.۹۳٪	۹۱.۱۸٪	۹۱.۳۲٪	۹۰.۶۲٪
-------------	--------	--------	--------	--------	--------

MobileNetV2 اصلاح شده	۹۱.۸۶٪	۹۱.۰۹٪	۹۲.۶۶٪	۹۲.۸۲٪	۹۱.۹۵٪
-----------------------	--------	--------	--------	--------	--------

Table 3. Classification results using MobileNetV2.

Deep Learning Model	Accuracy	Sensitivity	Specificity	Precision	F1 Score
MobileNetV2	90.54%	89.93%	91.18%	91.32%	90.62%
Modified MobileNetV2	91.86%	91.09%	92.66%	92.82%	91.95%

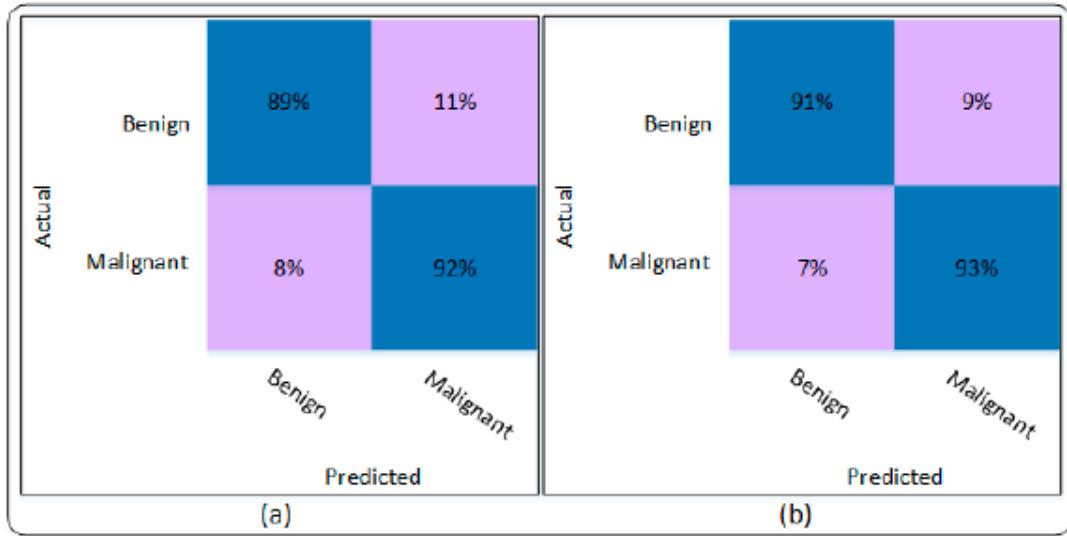


Figure 7. Confusion matrix of the proposed technique; (a) MobileNetV2 model, (b) Modified MobileNetV2 model.

شکل ۷. ماتریس اشتباہ تکنیک پیشنهادی؛ (الف) مدل MobileNetV2 ، (ب) مدل MobileNetV2 اصلاح شده.

۹۳٪ را به دست می آورد، در حالی که تنها ۷٪ از کلاس بدینم به عنوان خوش خیم تشخیص داده شد. از جدول ۳ و شکل ۷ مشاهده می شود که MobileNetV2 اصلاح شده پیشنهادی عملکرد بهتری را بر اساس پارامتر های ارزیابی نشان داد. نمودار های دقت و اتلاف MobileNetV2 اصلاح شده پیشنهادی در شکل ۸ ارائه شده است.

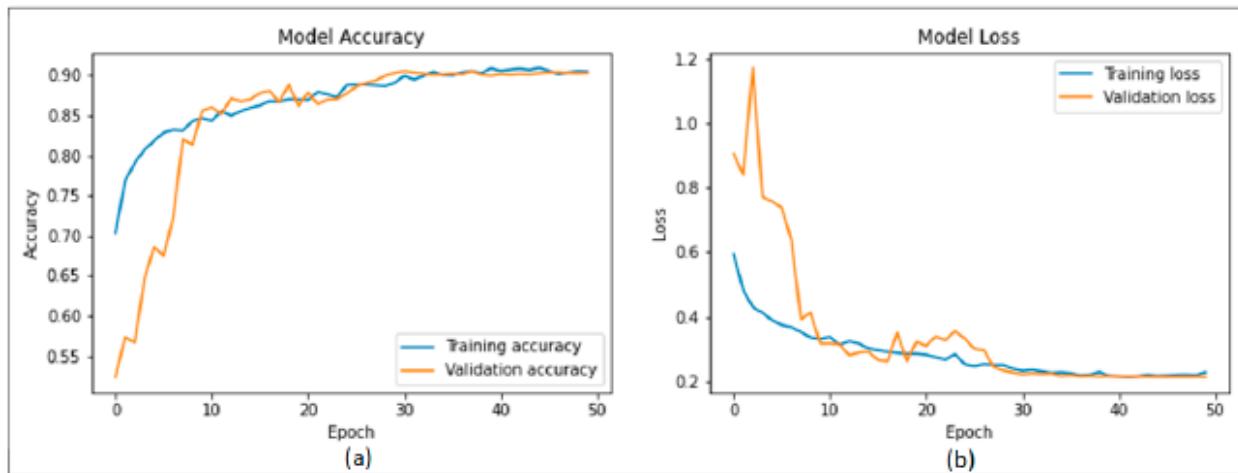


Figure 8. Training plots of Modified MobileNetV2; (a) accuracy plot, (b) loss plot.

شکل ۸. نمودارهای آموزشی MobileNetV2 اصلاح شده؛ (الف) نمودار دقت، (ب) نمودار اتلاف.

۴.۳ نتایج بر اساس DenseNet201

این بخش فرعی نتایج به دست آمده با استفاده از DenseNet201 و DenseNet201 اصلاح شده پیشنهادی را ارائه می‌دهد. نتایج دقیق در جدول ۴ ارائه شده است که بر اساس چندین پارامتر ارزیابی است. جدول ۴ نشان می‌دهد که دقت %۹۴.۰۹ را در مجموعه داده استفاده شده به دست آورد. علاوه بر این، حساسیت، ویژگی، دقت و نمره F1 به ترتیب %۹۲.۱۶، %۹۶.۰۵، %۹۵.۹۶ و %۹۴.۰۲ ثبت شد DenseNet201. اصلاح شده پیشنهادی برتری خود را نسبت به DenseNet201 از پیش آموزش دیده با دستیابی به دقت %۹۵.۵۰ نشان می‌دهد. برای اطمینان بیشتر از صحت نتایج به دست آمده، چندین پارامتر دیگر نیز در نظر گرفته شد. حساسیت و ویژگی به دست آمده توسط مدل اصلاح شده به ترتیب %۹۶.۹۶ و %۹۷.۰۶ است. در حالی که دقت و نمره F1 به ترتیب %۹۷.۰۲ و %۹۵.۴۶ ثبت شد. نتایج نشان داده در جدول ۴ همچنین با استفاده از ماتریس اشتباه نشان داده شده در شکل ۹ تأیید می‌شود.

جدول ۴. نتایج طبقه‌بندی با استفاده از DenseNet201 اصلاح شده.

نمودار F1 دقت	ویژگی	حساسیت	مدل یادگیری عمیق
DenseNet201 %۹۴.۰۹%	%۹۲.۱۶%	%۹۶.۰۵%	%۹۵.۹۶% %۹۴.۰۲%
DenseNet201 اصلاح شده %۹۵.۵۰%	%۹۳.۹۶%	%۹۷.۰۶%	%۹۷.۰۲% %۹۵.۴۶%

ماتریس اشتباه DenseNet201 در شکل ۹ الف نشان داده شده است، در حالی که شکل ۹ ب ماتریس اشتباه DenseNet201 اصلاح شده پیشنهادی را نشان می‌دهد. شکل ۹ الف نشان می‌دهد که بیماری خوش خیم با دقت %۹۲ به درستی طبقه‌بندی شد، در حالی که تنها ۸٪ از بیماری خوش خیم به اشتباه به عنوان بدхیم طبقه‌بندی شد، در حالی که بر اساس ماتریس اشتباه، بیماری بدخیم با دقت %۹۶ طبقه‌بندی شد. در این مرور، بیماری بدخیم تنها ۴٪ به اشتباه به عنوان خوش خیم طبقه‌بندی شد. شکل ۹ ب ماتریس اشتباه DenseNet201 اصلاح شده پیشنهادی را ارائه می‌دهد. ماتریس اشتباه نشان می‌دهد که بیماری‌های خوش خیم و بدخیم به ترتیب با دقت %۹۴ و %۹۷ به درستی طبقه‌بندی شدند. تنها ۶٪ از بیماری خوش خیم به اشتباه به عنوان بدخیم طبقه‌بندی شد. نمودارهای دقت و اتلاف DenseNet201 اصلاح شده پیشنهادی در شکل ۱۰ نشان داده شده است.

شکل ۹. ماتریس اشتباه تکنیک پیشنهادی. (الف) مدل DenseNet201 ، (ب) مدل DenseNet201 اصلاح شده.

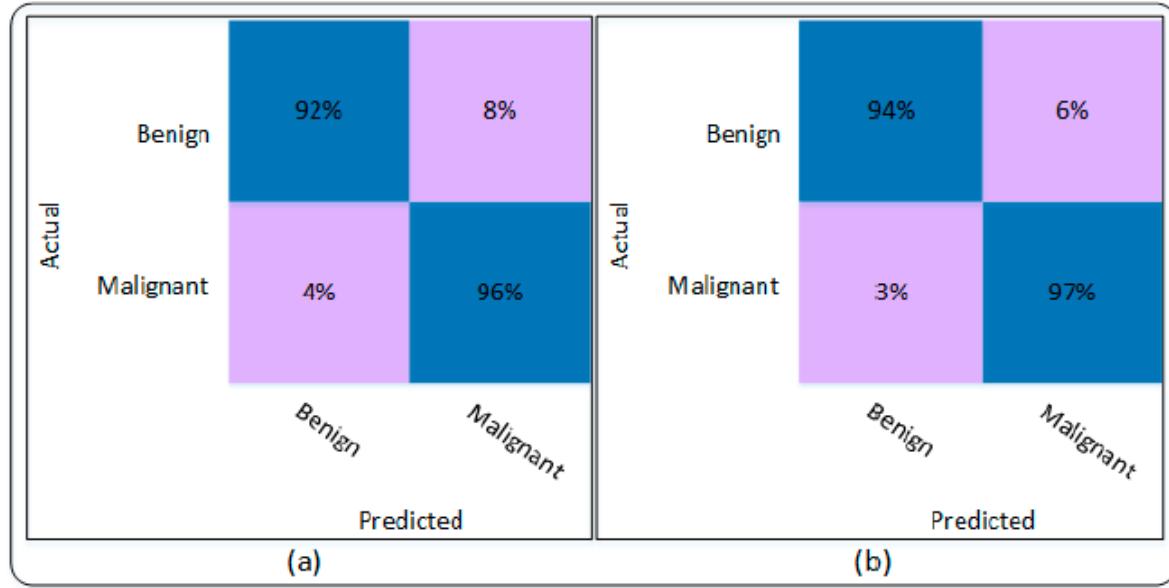


Figure 9. Confusion matrix of the proposed technique. (a) DenseNet201 model, (b) Modified DenseNet201 model.

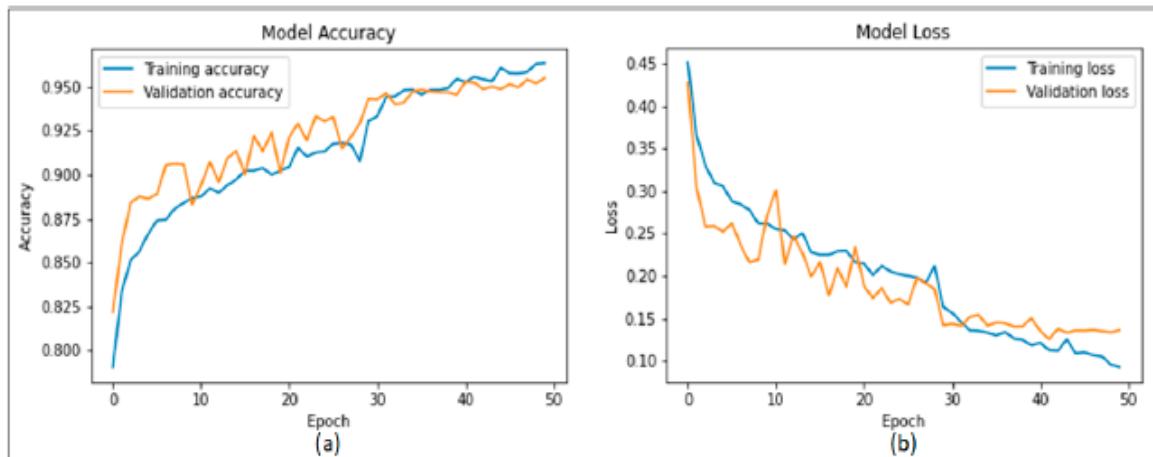


Figure 10. Training plots of Modified DenseNet201 (a) Accuracy plot (b) Loss plot.

شکل ۱۰. نمودارهای آموزشی DenseNet201 اصلاح شده (الف) نمودار دقت (ب) نمودار اتلاف.

علاوه بر این، یک نمایش بصری از نقاط ضایعه با استفاده از تکنیک Grad-CAM تشخیص داده می‌شود. همانطور که بحث شد، به طور ضعیف نقطه ضایعه را مکانیابی می‌کند که قطعاً می‌تواند به پرستن پزشکی در تشخیص و شناسایی کمک کند. با استفاده از تکنیک پیشنهادی، آشکار است که ویژگی‌های آموخته شده به خوبی آموزش دیده‌اند و قادر به تشخیص و مکانیابی نقاط ضایعه بر اساس اطلاعات ویژگی هستند. شکل ۱۱ چند نمونه تصویر را نشان می‌دهد که هدف Grad-CAM را به صورت بصری نشان می‌دهند. نمونه‌های نشان داده شده در زیر نتایج DenseNet201 اصلاح شده پیشنهادی با دقت % ۹۵.۵ هستند. شکل ۱۱ االف تصویر اصلی را نشان می‌دهد، در حالی که شکل ۱۱ ب مکانیابی مربوطه نقطه ضایعه مبنی بر Grad-CAM را نشان می‌دهد.

(الف)

(ب)

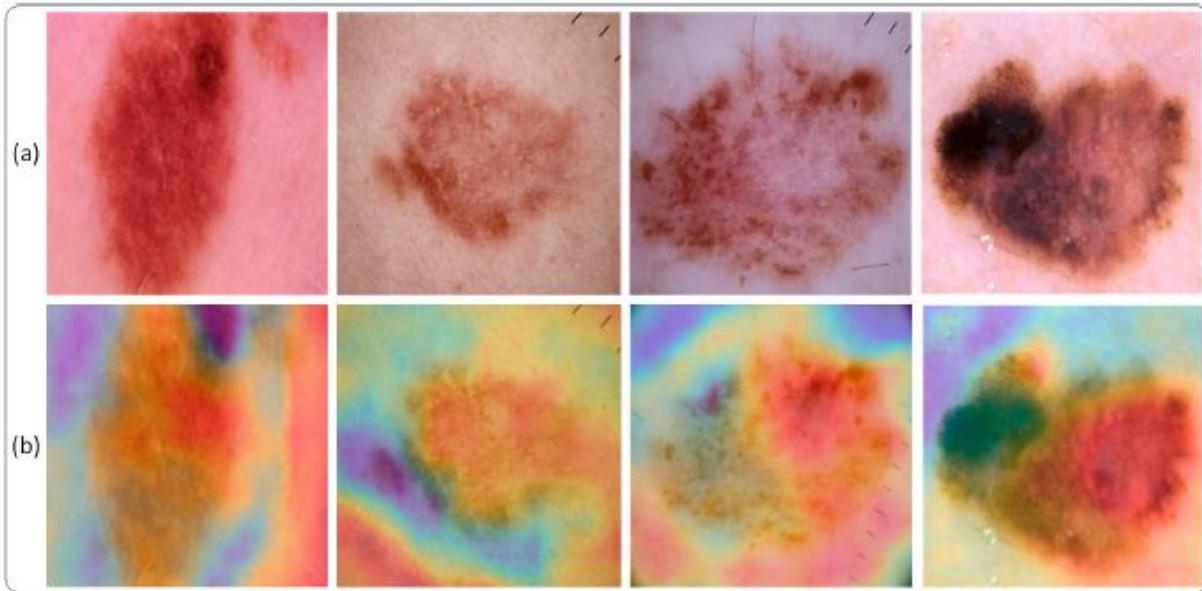


Figure 11. An Illustration of detection of lesion spots using Modified DenseNet201 based on Grad-CAM (a) shows the input image and (b) depicts the final output of Modified DenseNet201 using Grad-CAM.

شکل ۱۱. نمایش تشخیص نقاط ضایعه با استفاده از DenseNet201 اصلاح شده مبتنی بر Grad-CAM (الف) تصویر ورودی را نشان می دهد و (ب) خروجی نهایی DenseNet201 اصلاح شده را با استفاده از Grad-CAM نشان می دهد.

۴.۴. تحلیل و مقایسه

نتایج در این بخش فرعی با مقایسه نتایج تکنیک پیشنهادی با مدل های از پیش آموزش دیده اصلی تحلیل شده است. علاوه بر این، نتایج همچنین با سایر تکنیک های موجود در ادبیات که برای طبقه بندی سرطان پوست استفاده شده اند، مقایسه شده است.

دقت های به دست آمده با استفاده از مدل های مختلف استفاده شده در این کار در شکل ۱۲ نشان داده شده است. مشاهده می شود که DenseNet201 اصلاح شده و MobileNetV2 اصلاح شده دارای نتایج تکنیک پیشنهادی در مقایسه با مدل های از پیش آموزش دیده اصلی DenseNet201 و MobileNetV2 عملکرد بهتری داشتند. علاوه بر این، همانطور که در شکل ۱۲ نشان داده شده است، DenseNet201 اصلاح شده پیشنهادی از سه مدل دیگر بهتر عمل می کند. تکنیک پیشنهادی با سایر تکنیک های موجود در ادبیات برای طبقه بندی سرطان پوست مقایسه شده است. جدول ۵ نشان می دهد که تکنیک پیشنهادی برتری خود را نسبت به سایر تکنیک ها با دستیابی موفقیت آمیز به دقت ۹۵.۵٪ نشان می دهد.

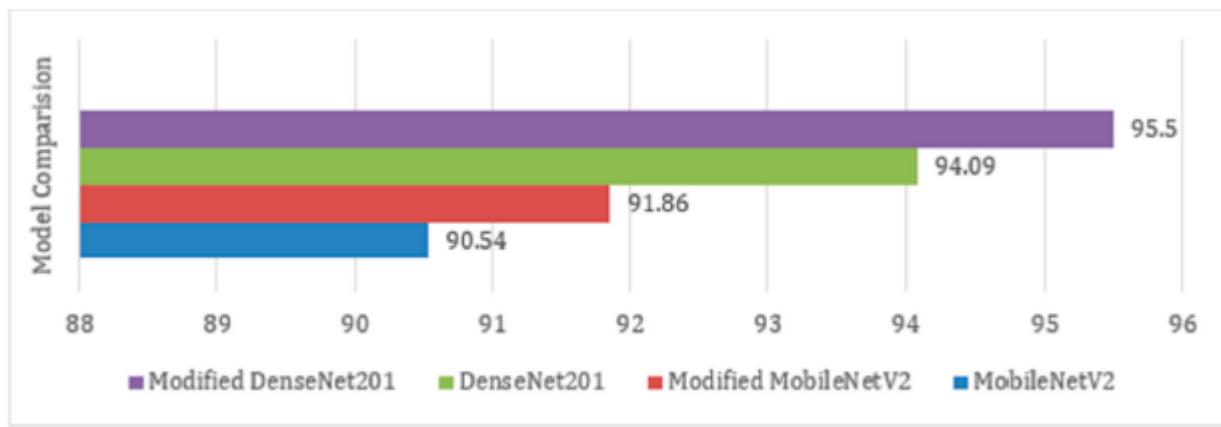


Figure 12. Performance comparison of the four models used in this work.

شکل ۱۲. مقایسه عملکرد چهار مدل استفاده شده در این کار.

جدول ۵. مقایسه با تکنیک‌های پیشرفته.

منابع	دقت	سال
[۲۳] اسرینیوسا و همکاران	۸۵.۳۴٪	۲۰۲۱
[۲۴] شاهین و همکاران	۹۱.۹۳٪	۲۰۲۱
[۲۵] فرهت و همکاران	۹۴.۳۶٪	۲۰۲۲
پیشنهادی	۹۵.۵۰٪	-

۵. نتیجه‌گیری

در این مقاله، مدل‌های از پیش آموزش دیده یادگیری عمیق DenseNet201 و MobileNetV2 با افزودن لایه‌های کانولوشن اضافی برای تشخیص مؤثر سرطان پوست اصلاح شدند. به طور خاص، برای هر دو مدل، اصلاح شامل قرار دادن سه لایه کانولوشن در انتهای هر دو مدل است. علاوه بر این، سر طبقه‌بندی با استفاده از یک لایه نرم‌افزاری دسته‌ای اصلاح شد و لایه طبقه‌بندی نهایی نیز مطابق با کلاس مسئله مورد نظر اصلاح شد. آزمایش‌ها نشان می‌دهند که عملکرد هر دو مدل پس از اصلاحات معماری افزایش یافت DenseNet201. اصلاح شده بالاترین دقیقت را در مقایسه با سه مدل دیگر استفاده شده در این مطالعه ارائه داد. مدل DenseNet201 اصلاح شده پیشنهادی می‌تواند با تغییرات جزئی برای تشخیص چندکلاسه سرطان پوست استفاده شود. علاوه بر این، استراتژی‌های بهینه‌سازی موجود در ادبیات می‌توانند برای نتایج بهبود یافته مورد استفاده قرار گیرند.

سهم نویسنده‌گان: ایده‌پردازی، M.Z.U.R.؛ روشناسی، F.A.؛ نرم‌افزار، F.A. و M.Z.U.R.؛ اعتبارسنجی، F.A. و M.Z.U.R.؛ تحلیل رسمی، M.Z.U.R.؛ تحقیق، S.S.J. و S.A.A.؛ منابع، M.Z.U.R.؛ مدیریت داده‌ها، F.A.؛ نگارش پیش‌نویس اولیه، M.Z.U.R.؛ نگارش—بازبینی و ویرایش، F.A. و M.Z.A.S.A.A.؛ مصورسازی، M.Z.U.R.؛ نظارت، F.A. و J.A.؛ مدیریت پروژه، J.A.؛ کسب بودجه، S.S.J. و S.A.A. همه نویسنده‌گان نسخه منتشر شده مقاله را خوانده و با آن موافق شدند.

تأمین مالی: محققان مایلند از معاونت تحقیقات علمی دانشگاه قاسم برای تأمین مالی انتشار این پژوهه تشکر کنند.

بیانیه رضایت آگاهانه: قابل اعمال نیست.

بیانیه دسترسی به داده‌ها: مجموعه داده استفاده شده در این تحقیق به صورت عمومی با نام:

"Skin Cancer": Malignant vs. Benign" در آدرس <https://www.kaggle.com/datasets/fanconic/skin-cancer-Malignant-vs-Benign>

(دسترسی در ۲۰ می ۱۴۰۲) در دسترس است.

تعارض منافع: نویسنده‌ان هیچ تعارض منافعی را اعلام نمی‌کنند.

References

1. AlSalman, A.S.; Alkaff, T.M.; Alzaid, T.; Binamer, Y. Nonmelanoma skin cancer in Saudi Arabia: Single center experience. *Ann. Saudi Med.* **2018**, *38*, 42–45. [CrossRef] [PubMed]
2. Nehal, K.S.; Bichakjian, C.K. Update on keratinocyte carcinomas. *N. Engl. J. Med.* **2018**, *379*, 363–374. [CrossRef] [PubMed]
3. American Cancer Society. Key Statistics for Melanoma Skin Cancer. 2022. Available online: <https://www.cancer.org/cancer/melanoma-skin-cancer/about/key-statistics.html> (accessed on 15 March 2022).
4. Albahar, M.A. Skin lesion classification using convolutional neural network with novel regularizer. *IEEE Access* **2019**, *7*, 38306–38313. [CrossRef]
5. Hasan, M.R.; Fatemi, M.I.; Khan, M.M.; Kaur, M.; Zagaria, A. Comparative Analysis of Skin Cancer (Benign vs. Malignant) Detection Using Convolutional Neural Networks. *J. Healthc. Eng.* **2021**, *2021*, 5895156. [CrossRef] [PubMed]
6. Oseni, O.G.; Olaitan, P.B.; Komolafe, A.O.; Olaofe, O.O.; Akinyemi, H.A.M.; Suleiman, O.A. Malignant skin lesions in Oshogbo, Nigeria. *Pan Afr. Med. J.* **2015**, *20*, 253. [CrossRef]
7. Fijalkowska, M.; Koziej, M.; Antoszewski, B. Detailed head localization and incidence of skin cancers. *Sci. Rep.* **2021**, *11*, 12391. [CrossRef]
8. Patel, A. Benign vs malignant tumors. *JAMA Oncol.* **2020**, *6*, 1488. [CrossRef]
9. Kaur, R.; Hosseini, H.G.; Sinha, R.; Linden, M. Melanoma Classification Using a Novel Deep Convolutional Neural Network with Dermoscopic Images. *Sensors* **2022**, *22*, 1134. [CrossRef]
10. Akamatsu, T.; Hanai, U.; Kobayashi, M.; Miyasaka, M. Pyogenic granuloma: A retrospective 10-year analysis of 82 cases. *Tokai J. Exp. Clin. Med.* **2015**, *40*, 110–114.
11. Marie-Lise, B.; Beauchet, A.; Aegeerter, P.; Saiag, P. Is dermoscopy (epiluminescence microscopy) useful for the diagnosis of melanoma?: Results of a meta-analysis using techniques adapted to the evaluation of diagnostic tests. *Arch. Dermatol.* **2001**, *137*, 1343–1350.
12. Redha, A.; Ragh, H.K. Skin lesion segmentation and classification using deep learning and handcrafted features. *arXiv* **2021**, arXiv:2112.10307.

13. Tripp, M.K.; Watson, M.; Balk, S.J.; Swetter, S.M.; Gershenwald, J.E. State of the science on prevention and screening to reduce melanoma incidence and mortality: The time is now. *CA Cancer J. Clin.* **2016**, *66*, 460–480. [CrossRef]
14. Khan, M.A.; Alqahtani, A.; Khan, A.; Alsubai, S.; Binbusayyis, A.; Iqbal, C.M.M.; Yong, H.S.; Cha, J. Cucumber Leaf Diseases Recognition Using Multi Level Deep Entropy-ELM Feature Selection. *Appl. Sci.* **2022**, *12*, 593. [CrossRef]
15. Attique, K.M.; Akram, T.; Sharif, M.; Shahzad, A.; Aurangzeb, K.; Alhussein, M.; Haider, S.I.; Altamrah, A. An implementation of normal distribution based segmentation and entropy controlled features selection for skin lesion detection and classification. *BMC Cancer* **2018**, *18*, 1–20.
16. Dorj, U.O.; Lee, K.K.; Choi, J.Y.; Lee, M. The skin cancer classification using deep convolutional neural network. *Multimed. Tools Appl.* **2018**, *77*, 9909–9924. [CrossRef]
17. Filho, R.; Pedrosa, P.; Peixoto, S.A.; da Nobrega, R.V.M.; Hemanth, D.J.; Medeiros, A.G.; Sangaiah, A.K.; de Albuquerque, V.H.C. Automatic histologically-closer classification of skin lesions. *Comput. Med. Imaging Graph.* **2018**, *68*, 40–54. [CrossRef]
18. Li, Y.; Shen, L. Skin lesion analysis towards melanoma detection using deep learning network. *Sensors* **2018**, *18*, 556. [CrossRef]
19. Saba, T.; Khan, M.A.; Rehman, A.; Marie-Sainte, S.L. Region extraction and classification of skin cancer: A heterogeneous framework of deep CNN features fusion and reduction. *J. Med. Syst.* **2019**, *43*, 289. [CrossRef]
20. Esteva, A.; Kuprel, B.; Novoa, R.A.; Ko, J.; Swetter, S.M.; Blau, H.M.; Thrun, S. Dermatologist-level classification of skin cancer with deep neural networks. *Nature* **2017**, *542*, 115–118. [CrossRef]
21. Le, D.N.T.; Le, H.X.; Ngo, L.T.; Ngo, H.T. Transfer learning with class-weighted and focal loss function for automatic skin cancer classification. *arXiv* **2020**, arXiv:2009.05977.
22. Iqbal, J.; Younus, M.; Walayat, K.; Kakar, M.U.; Ma, J. Automated multi-class classification of skin lesions through deep convolutional neural network with dermoscopic images. *Comput. Med. Imaging Graph.* **2021**, *88*, 101843. [CrossRef] [PubMed]
23. Srinivasu, P.N.; SivaSai, J.G.; Ijaz, M.F.; Bhoi, A.K.; Kim, W.; Kang, J.J. Classification of skin disease using deep learning neural networks with MobileNet V2 and LSTM. *Sensors* **2021**, *21*, 2852. [CrossRef] [PubMed]
24. Ali, M.S.; Miah, M.S.; Haque, J.; Rahman, M.M.; Islam, M.K. An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models. *Mach. Learn. Appl.* **2021**, *5*, 100036. [CrossRef]
25. Afza, F.; Sharif, M.; Khan, M.A.; Tariq, U.; Yong, H.S.; Cha, J. Multiclass Skin Lesion Classification Using Hybrid Deep Features Selection and Extreme Learning Machine. *Sensors* **2022**, *22*, 799. [CrossRef] [PubMed]
26. Chaturvedi, S.S.; Tembherne, J.V.; Diwan, T. A multi-class skin Cancer classification using deep convolutional neural networks. *Multimed. Tools Appl.* **2020**, *79*, 28477–28498. [CrossRef]
27. Skin Cancer: Malignant vs. Benign. Available online: <https://www.kaggle.com/datasets/fanconic/skin-cancer-malignant-vs-benign> (accessed on 20 May 2022).

28. ISIC Archive. Available online: <https://www.isic-archive.com/> (accessed on 20 May 2022).
29. Ding, S.; Li, R.; Wu, S. A novel composite forecasting framework by adaptive data preprocessing and optimized nonlinear grey Bernoulli model for new energy vehicles sales. *Commun. Nonlinear Sci. Numer. Simul.* **2021**, *99*, 105847. [CrossRef]
30. Khan, E.; Rehman, M.Z.U.; Ahmed, F.; Khan, M.A. Classification of Diseases in Citrus Fruits using SqueezeNet. In Proceedings of the 2021 International Conference on Applied and Engineering Mathematics (ICAEM), London, UK, 30–31 August 2021; pp. 67–72.
31. Park, C.; Kim, M.W.; Park, C.; Son, W.; Lee, S.M.; Jeong, H.S.; Kang, J.W.; Choi, M.H. Diagnostic Performance for Detecting Bone Marrow Edema of the Hip on Dual-Energy CT: Deep Learning Model vs. Musculoskeletal Physicians and Radiologists. *Eur. J. Radiol.* **2022**, *152*, 110337. [CrossRef]
32. Yang, J.; Lu, H.; Li, C.; Hu, X.; Hu, B. Data Augmentation for Depression Detection Using Skeleton-Based Gait Information. *arXiv* **2022**, arXiv:2201.01115. [CrossRef]
33. Albawi, S.; Mohammed, T.A.; Al-Zawi, S. Understanding of a convolutional neural network. In Proceedings of the 2017 International Conference on Engineering and Technology (ICET), Antalya, Turkey, 21–23 August 2017; pp. 1–6.
34. Sandler, M.; Howard, A.; Zhu, M.; Zhmoginov, A.; Chen, L.C. Mobilenetv2: Inverted residuals and linear bottlenecks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 18–23 June 2018; pp. 4510–4520.
35. Huang, G.; Liu, Z.; Maaten, L.V.D.; Weinberger, K.Q. Densely connected convolutional networks. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, HI, USA, 21–26 July 2017; pp. 4700–4708.
36. Weiss, K.; Khoshgoftaar, T.M.; Wang, D.D. A survey of transfer learning. *J. Big Data* **2016**, *3*, 9. [CrossRef]
37. Deng, J.; Dong, W.; Socher, R.; Li, L.J.; Li, K.; Fei-Fei, L. Imagenet: A large-scale hierarchical image database. In Proceedings of the 2009 IEEE Conference on Computer Vision and Pattern Recognition, Miami, FL, USA, 20–25 June 2009; pp. 248–255.